

	Министерство науки и высшего образования Российской Федерации Федеральное государственное бюджетное образовательное учреждение высшего образования «Московский государственный технический университет имени Н.Э. Баумана (национальный исследовательский университет)» (МГТУ им. Н.Э. Баумана)
---	--

ФАКУЛЬТЕТ БИОМЕДИЦИНСКАЯ ТЕХНИКА

КАФЕДРА БИОМЕДИЦИНСКИЕ ТЕХНИЧЕСКИЕ СИСТЕМЫ

РАСЧЕТНО-ПОЯСНИТЕЛЬНАЯ ЗАПИСКА

К КУРСОВОМУ ПРОЕКТУ

НА ТЕМУ:

Разработка модели для предсказания параметров симуляций (MD) по геометрии самоорганизованных частиц с использованием глубокого обучения для анализа пространственных конфигураций в коллоидных системах

Группа БМТ1-23М

Студент

_____	<u>Нафикова Р.Р.</u>
подпись, дата	фамилия, и.о.
_____	<u>Жуков К.П.</u>
подпись, дата	фамилия, и.о.
_____	<u>Кохановская А.В.</u>
подпись, дата	фамилия, и.о.
_____	<u>Походяев О. И.</u>
подпись, дата	фамилия, и.о.
_____	<u>Бондарева А.А.</u>
подпись, дата	фамилия, и.о.

Руководитель курсового проекта

_____	<u>Мошкова А.А.</u>
подпись, дата	фамилия, и.о.

2026 г.

СОДЕРЖАНИЕ

Введение	4
1 Постановка задачи	6
1.1 Прямая и обратная задачи	6
1.2 Формальная постановка	6
1.3 Критерии качества	7
1.4 Этапы работы	7
2 Обзор предметной области	8
2.1 Самоорганизация в коллоидных системах	8
2.2 Самоорганизация в условиях конфинмента	8
2.3 Молекулярно-динамическое моделирование	9
2.4 Структурные дескрипторы конфигураций	10
2.5 Машинное обучение в физике мягкой материи	11
3 Подготовка и предобработка данных	12
3.1 Исходные данные моделирования	12
3.2 Признаковое описание для классических моделей	12
3.3 Графовое представление для нейронной сети	12
3.4 Аугментация и разбиение выборки	13
4 Классические методы машинного обучения	15
4.1 Гребневая регрессия с ядрами	15
4.2 Случайный лес	15
4.3 Программная реализация классических моделей	16
5 Графовая нейронная сеть	18
5.1 Графовые свёрточные сети	18
5.2 Архитектура модели PhysicsGNN	18
5.3 Обучение модели	19
5.4 Подбор гиперпараметров	20
5.5 Программная реализация	21
6 Анализ результатов	22

6.1	Результаты классических моделей	22
6.2	Результаты графовой нейронной сети	23
6.3	Сравнительный анализ моделей	25
Заключение		27

ВВЕДЕНИЕ

Управляемая самоорганизация коллоидных частиц представляет собой одно из ключевых направлений современной физики мягкой материи. Способность задавать и перестраивать структуру ансамблей микрочастиц с помощью внешних магнитных и электрических полей открывает широкие возможности как для фундаментальных исследований фазовых переходов и коллективной динамики, так и для прикладных задач микрофабрикации, создания адаптивных материалов и биомиметических платформ типа «орган-на-чипе» [1, 2]. Особый интерес представляет поведение коллоидных систем в условиях геометрического ограничения, когда характерный размер ячейки сопоставим с размером частиц: пространственное ограничение качественно изменяет характер коллективной динамики и приводит к появлению структурных состояний, не реализующихся в объёмных системах [3].

Прямая задача в этой области — предсказание структуры системы по заданным управляющим параметрам (плотности, высоте конфайнмента, силе дипольного взаимодействия) — традиционно решается методами молекулярной динамики. Однако вычислительная стоимость такого моделирования высока, а во многих практически важных ситуациях (например, при анализе экспериментальных снимков) возникает потребность в решении *обратной* задачи: восстановления управляющих параметров по уже наблюдаемой геометрии конфигурации. Именно эта постановка лежит в основе настоящей работы.

Развитие методов машинного обучения позволяет строить эффективные суррогатные модели, аппроксимирующие сложные физические зависимости. При этом возникает естественный вопрос о том, какое представление данных является наиболее информативным: набор заранее вычисленных физических дескрипторов (параметров порядка, коэффициента диффузии, характеристик диаграммы Вороного) либо непосредственно геометрия системы, обрабатываемая графовой нейронной сетью. Сопоставление этих двух подходов составляет методологическое ядро проекта.

Настоящий отчёт посвящён разработке полного программного конвейера (пайплайна), включающего подготовку данных, формирование признакового и графового представлений, реализацию и обучение трёх моделей различной сложности, а также сравнительный анализ их качества. Работа вы-

полнена на данных молекулярно-динамического моделирования дипольных коллоидов под конфайнментом, согласующихся с опубликованным исследованием научного коллектива [4].

1 Постановка задачи

1.1 Прямая и обратная задачи

Рассматриваемая система описывается набором управляющих физических параметров: плотностью ρ , высотой конфайнмента h и дипольным моментом частиц p (в работе используется обозначение $p \equiv \mu$, соответствующее силе индуцированного внешним полем взаимодействия). Прямая задача состоит в определении равновесной структуры ансамбля частиц по заданному набору (ρ, h, p) и решается методом молекулярной динамики. В результате моделирования формируется пространственная конфигурация частиц, обладающая определёнными структурными признаками — числом слоёв, типом симметрии локального окружения, наличием цепочечных (змееобразных) и триплетных структур.

Обратная задача, решаемая в настоящей работе, заключается в восстановлении управляющих параметров h и p по наблюдаемой геометрии конфигурации. Плотность ρ при этом считается известной и используется в качестве дополнительного входного признака, поскольку она задаётся при подготовке образца и легко измеряется. Таким образом, требуется построить отображение

$$\mathcal{F} : \{\text{геометрия конфигурации}, \rho\} \longrightarrow (h, p). \quad (1)$$

1.2 Формальная постановка

Пусть имеется обучающая выборка $\{(\mathcal{C}_k, \rho_k, h_k, p_k)\}_{k=1}^M$, где $\mathcal{C}_k$ — конфигурация k -й симуляции. Требуется построить модель $\hat{\mathcal{F}}_\theta$ с параметрами θ , минимизирующую ошибку предсказания целевого вектора $\mathbf{y} = (h, p)$:

$$\theta^* = \arg \min_{\theta} \frac{1}{M} \sum_{k=1}^M \|\hat{\mathcal{F}}_\theta(\mathcal{C}_k, \rho_k) - \mathbf{y}_k\|_2^2. \quad (2)$$

В работе рассматриваются два принципиально различных способа представления конфигурации $\mathcal{C}_k$:

- *векторное признаковое* описание — набор предварительно вычисленных физических дескрипторов (используется в классических моделях машинного обучения);
- *графовое* описание — граф, вершинами которого являются частицы, а рёб-

рами — их пространственные связи (используется в графовой нейронной сети).

1.3 Критерии качества

Для оценки качества восстановления каждой из двух целевых величин используются три стандартные метрики регрессии: коэффициент детерминации R^2 , средняя абсолютная ошибка MAE и корень из среднеквадратичной ошибки RMSE:

$$\begin{aligned} R^2 &= 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}, \\ \text{MAE} &= \frac{1}{N} \sum_i |y_i - \hat{y}_i|, \\ \text{RMSE} &= \sqrt{\frac{1}{N} \sum_i (y_i - \hat{y}_i)^2}, \end{aligned} \tag{3}$$

где y_i — истинное значение, $\hat{y}_i$ — предсказание модели, $\bar{y}$ — среднее по выборке, N — число объектов. Коэффициент R^2 характеризует долю объяснённой дисперсии (идеальное значение $R^2 = 1$), а MAE и RMSE выражают ошибку в физических единицах целевой величины.

1.4 Этапы работы

В соответствии с планом проекта решение задачи разбито на следующие этапы: сбор и проверка данных молекулярно-динамического моделирования; предобработка и формирование двух представлений конфигураций; реализация baseline-моделей (гребневой регрессии и случайного леса) на признаковом описании; реализация основной модели — графовой нейронной сети — на геометрическом описании; подбор гиперпараметров, обучение и валидация всех моделей; сравнительный анализ результатов.

2 Обзор предметной области

2.1 Самоорганизация в коллоидных системах

Самоорганизация — фундаментальное явление, лежащее в основе формирования упорядоченных структур в физических, химических и биологических системах. В коллоидных системах процессом самосборки можно управлять путём приложения внешних магнитного или электрического полей, которые индуцируют направленное взаимодействие между частицами [2, 5]. Под действием перпендикулярного к плоскости образца магнитного поля изначально немагнитные суперпарамагнитные микрочастицы приобретают наведённый дипольный момент, в результате чего между ними возникает дальнodelствующее дипольное взаимодействие. Сила этого взаимодействия пропорциональна квадрату напряжённости поля и служит управляющим параметром p , что позволяет в едином образце наблюдать формирование различных упорядоченных фаз, коллективную динамику и фазовые переходы.

Управляемые коллоидные системы выступают модельными объектами для изучения фундаментальных явлений физики конденсированного состояния, поскольку медленные по сравнению с атомными масштабы времени и доступность прямого оптического наблюдения делают возможным детальное исследование процессов кристаллизации, стеклования и образования топологических дефектов [1].

2.2 Самоорганизация в условиях конфайнмента

Практический и фундаментальный интерес к самоорганизации существенно возрастает в условиях пространственного ограничения, когда движение частиц ограничено зазором между двумя плоскими стенками с высотой h , сопоставимой с диаметром частицы d (режим $h < 2d$). В таких условиях поведение системы определяется не только собственными взаимодействиями частиц, но и влиянием границ, анизотропией доступного пространства и изменёнными гидродинамическими условиями [3]. Введение конфайнмента приводит к возникновению новых структурных состояний и изменению кинетики самосборки.

Согласно исследованию, на данных которого основана настоящая работа [4], конфайнмент действует не как простое геометрическое ограничение, а как активный управляющий параметр, определяющий путь самосборки. При

сильном ограничении ($h \lesssim 1,1$) система формирует преимущественно монослойные структуры с гексагональной симметрией, а увеличение дипольного момента p способствует росту линейных цепочечных агрегатов («змеек»). При увеличении высоты конфинмента появляются дополнительные степени свободы вне плоскости, что благоприятствует ветвлению и образованию триплетных сетей, а при больших p и h — формированию многослойных структур. Таким образом, в пространстве параметров p – h возникает богатая фазовая диаграмма с чёткими границами между областями доминирования различных структурных мотивов.

2.3 Молекулярно-динамическое моделирование

Исходные данные получены методом классической молекулярной динамики для трёхмерной системы из $N = 10^4$ частиц. Взаимодействие частиц складывается из короткодействующего отталкивания, описываемого потенциалом Уикса—Чандлера—Андерсена (WCA), и дальнодействующего дипольного взаимодействия:

$$\varphi_{\text{WCA}}(r) = \begin{cases} 4\varepsilon \left[\left(\frac{\sigma_{ij}}{r} \right)^{12} - \left(\frac{\sigma_{ij}}{r} \right)^6 \right] + \varepsilon, & r \leq 2^{1/6} \sigma_{ij}, \\ 0, & r > 2^{1/6} \sigma_{ij}, \end{cases} \quad (4)$$

$$\varphi_{dd}(r) = \frac{\mathbf{p}_i \cdot \mathbf{p}_j}{r^3} - \frac{3(\mathbf{p}_i \cdot \mathbf{r})(\mathbf{p}_j \cdot \mathbf{r})}{r^5}, \quad (5)$$

где $\sigma_{ij} = (\sigma_i + \sigma_j)/2$ — средний диаметр пары частиц, $\mathbf{p}_{i,j}$ — дипольные моменты, $\mathbf{r}$ — радиус-вектор между частицами. Динамика системы рассчитывалась с использованием термостата Ланжевена:

$$m_i \ddot{\mathbf{r}}_i = \mathbf{F}_i - m_i \gamma_i \dot{\mathbf{r}}_i + \boldsymbol{\xi}_i, \quad (6)$$

где $\mathbf{F}_i$ — суммарная сила со стороны других частиц, γ_i — коэффициент трения, $\boldsymbol{\xi}_i$ — случайная сила, удовлетворяющая флуктуационно-диссипационному соотношению. Моделирование выполнено в пакете HOOMD-blue [11, 12] при фиксированной приведённой температуре $T = 1$; параметры моделирования приведены в таблице 1.

Таблица 1 — Параметры молекулярно-динамического моделирования

Параметр	Значение
Число частиц N	10^4
Диаметр частиц σ_i	1 (приведённые единицы)
Радиус обрезания взаимодействия r_{cut}	$15 \sigma_i$
Температура термостата T	1 (приведённые единицы)
Шаг интегрирования Δt	10^{-4}
Число шагов	10^6
Высота конфайнмента h	от 1,0 до 1,475 с шагом 0,025
Дипольный момент p	от 1,0 до 10,6 (для $\rho = 0,7$); от 5,0 до 14,6 (для $\rho = 0,8$) с шагом 0,2
Начальная конфигурация	гексагональная решётка

2.4 Структурные дескрипторы конфигураций

Для количественной характеристики структуры в исходном исследовании и в настоящей работе используется ряд физических дескрипторов, вычисляемых по равновесной конфигурации и траектории движения частиц.

Ориентационные параметры порядка ψ_n характеризуют локальную симметрию окружения частицы и определяются как

$$\psi_n(\mathbf{r}_j) = \frac{1}{N_j} \sum_{l=1}^{N_j} e^{in\theta_{jl}}, \quad (7)$$

где суммирование ведётся по N_j ближайшим соседям частицы j , а θ_{jl} — угол связи между частицами j и l . В работе используются параметры $\psi_3, \psi_4, \psi_5, \psi_6$: высокое значение ψ_6 соответствует гексагональному (плотнупакованному) порядку, ψ_4 — квадратной симметрии.

Коэффициент диффузии D извлекается из среднеквадратичного смещения частиц (MSD) как наклон его линейного участка. Для квазидвумерного движения

$$D = \lim_{t \rightarrow \infty} \frac{\langle |\mathbf{r}(t) - \mathbf{r}(0)|^2 \rangle}{4t}. \quad (8)$$

Коэффициент диффузии служит индикатором подвижности системы (жидкая или кристаллическая фаза) и тесно связан с силой дипольного связывания: усиление взаимодействия подавляет диффузию.

Анализ диаграммы Вороного, число структурных слоёв вдоль оси конфинмента, средняя длина змееобразных цепочек и количество триплетов дополняют набор дескрипторов, отражая особенности пространственной организации частиц.

2.5 Машинное обучение в физике мягкой материи

Для построения суррогатных моделей применяются методы различной сложности. Гребневая регрессия с ядрами (Kernel Ridge Regression, KRR) и случайный лес (Random Forest) [6] работают с фиксированным вектором рукотворных признаков и являются классическими методами регрессии, реализованными в библиотеке `scikit-learn` [7]. Графовые нейронные сети снимают необходимость ручного конструирования признаков, обучаясь непосредственно на структуре данных; в настоящей работе используется кристаллическая графовая свёртка `CGConv` [8], изначально предложенная для предсказания свойств кристаллов по графу атомов и реализованная в библиотеке `PyTorch Geometric` [9] на базе фреймворка `PyTorch` [10].

3 Подготовка и предобработка данных

3.1 Исходные данные моделирования

Результаты молекулярно-динамического моделирования представлены траекторными файлами формата `.lammprj`, имя каждого из которых кодирует параметры симуляции: плотность ρ , высоту конфайнмента h и дипольный момент p . Из каждого файла извлекается последний (равновесный) кадр траектории: считываются границы расчётной ячейки и трёхмерные координаты всех частиц. Общее число обработанных конфигураций составило 8757; в данных представлено семь значений плотности ($\rho = 0,30; 0,40; \dots; 0,90$).

3.2 Признаковое описание для классических моделей

Для классических моделей машинного обучения каждая конфигурация описывается вектором физических дескрипторов, вычисляемых по сопутствующим файлам анализа симуляции. Число структурных слоёв определяется по распределению частиц вдоль оси z как количество пиков сглаженной гистограммы; коэффициент диффузии — по наклону второй половины кривой MSD согласно (8); параметры порядка ψ_3 – ψ_6 — усреднением соответствующих файлов; характеристики диаграммы Вороного, признак фазового расслоения, число триплетов и средняя длина змеек — из результатов структурного анализа. Полный перечень признаков приведён в таблице 2.

Гребневая регрессия использует сокращённый набор из девяти наиболее устойчивых признаков (плотность, число слоёв, коэффициент диффузии, признак жидкой фазы, четыре параметра порядка и доминирующая симметрия), тогда как случайный лес работает с полным набором, включающим характеристики Вороного, триплеты и длину змеек. Перед подачей в гребневую регрессию признаки стандартизируются (приведение к нулевому среднему и единичной дисперсии), что необходимо для корректной работы ядровых методов.

3.3 Графовое представление для нейронной сети

Для графовой нейронной сети конфигурация представляется в виде неориентированного графа $G = (V, E)$, вершины которого соответствуют частицам, а рёбра соединяют частицы, расстояние между которыми не превышает радиуса обрезания $r_{\text{cut}}^G = 2,5\sigma$. Поиск соседей выполняется с помощью k -

Таблица 2 — Признаковое описание конфигурации для классических моделей

Признак	Физический смысл
density (ρ)	Плотность системы (известный параметр)
num_layers	Число структурных слоёв вдоль оси конфайнмента
diffusion_coeff	Коэффициент диффузии (подвижность системы)
is_liquid	Признак жидкой фазы ($D \geq 0,05$)
psi_3 ... psi_6	Ориентационные параметры порядка $\psi_3, \psi_4, \psi_5, \psi_6$
dominant_k	Доминирующая локальная симметрия
voronoi_peaks	Число пиков структурного фактора Вороного
voronoi_peak_ratio	Отношение позиций крайних пиков
is_phase_separated	Признак фазового расслоения
triplet_raw_count	Число триплетных мотивов
snake_length_avg	Средняя длина змееобразных цепочек

мерного дерева (сKDTree). Признак каждой вершины принимается единичным (все частицы идентичны), а вектор признаков ребра содержит компоненты относительного смещения и расстояние: $\mathbf{e}_{ij} = (\Delta x, \Delta y, \Delta z, r)$. Плотность ρ передаётся как глобальный признак графа, а целевым вектором служит пара (h, p) . Принцип построения графа иллюстрирует листинг в приложении А.

3.4 Аугментация и разбиение выборки

Поскольку полная конфигурация из 10^4 частиц образует чрезмерно большой граф, из каждой симуляции вырезаются четыре случайных пространственных фрагмента (патча): по осям x и y выбирается половина расчётной ячейки, а вдоль оси конфайнмента z фрагмент сохраняется целиком. Такое разбиение, во-первых, уменьшает размер графа до приблизительно 2500 частиц, во-вторых, выполняет роль аугментации данных, увеличивая объём обучающей выборки в четыре раза и предоставляя сети несколько независимых «взглядов» на одну и ту же физическую систему. Сохранение полной высоты ячейки гарантирует, что информация о слоистой структуре, критичная для определения h , не теряется.

Для обеспечения сбалансированного представления всех плотностей выполняется стратифицированное разбиение исходных симуляций в пропорции 70/15/15 на обучающую, валидационную и тестовую выборки. Разбие-

ние проводится на уровне симуляций, а не отдельных патчей, что исключает утечку данных между выборками (фрагменты одной симуляции не попадают одновременно в обучение и контроль). Количественные характеристики выборок приведены в таблице 3.

Таблица 3 — Разбиение выборки и аугментация данных

Показатель	Обучение	Валидация	Тест
Число симуляций (до аугментации)	6227	1334	1335
Доля выборки	70 %	15 %	15 %
Патчей на симуляцию	4	4	4
Число графов (после аугментации)	24 904	5336	5340

Классические модели используют по одному вектору признаков на симуляцию (без патч-аугментации), тогда как графовая сеть обучается на аугментированных графах; при оценке качества предсказания сети по четырём патчам одной симуляции усредняются (ансамблирование), что снижает дисперсию итоговой оценки.

4 Классические методы машинного обучения

В качестве базовых (baseline) решений реализованы две модели регрессии, работающие с признаковым описанием конфигураций: гребневая регрессия с ядрами и случайный лес. Обе модели решают задачу многомерной регрессии, предсказывая одновременно две целевые величины h и p .

4.1 Гребневая регрессия с ядрами

Гребневая регрессия с ядрами (Kernel Ridge Regression, KRR) объединяет линейную регрессию с L_2 -регуляризацией и ядровый переход в пространство признаков высокой размерности. В исходной форме метод минимизирует функционал

$$\min_{\mathbf{w}} \sum_{i=1}^N (y_i - \mathbf{w}^\top \phi(\mathbf{x}_i))^2 + \alpha \|\mathbf{w}\|_2^2, \quad (9)$$

где $\phi(\cdot)$ — неявное отображение в спрямляющее пространство, а α — коэффициент регуляризации. Благодаря ядровому трюку предсказание выражается через ядровую функцию $K(\mathbf{x}, \mathbf{x}')$ без явного вычисления ϕ . В работе исследованы три ядра: радиально-базисное (RBF), полиномиальное (poly) и сигмоидальное (sigmoid). Для RBF-ядра

$$K(\mathbf{x}, \mathbf{x}') = \exp(-\gamma \|\mathbf{x} - \mathbf{x}'\|_2^2), \quad (10)$$

где параметр γ задаёт ширину ядра. Многомерность выхода обеспечивается обёрткой `MultiOutputRegressor`, обучающей отдельную модель для каждой целевой величины.

Подбор гиперпараметров выполнен полным перебором по сетке (таблица 4) с выбором конфигурации, минимизирующей суммарную ошибку $\text{MAE}_h + \text{MAE}_p$ на валидационной выборке. Результаты перебора для трёх ядер представлены на рисунке 1 в виде тепловых карт.

4.2 Случайный лес

Случайный лес (Random Forest) [6] — ансамблевый метод, строящий совокупность решающих деревьев на бутстрэп-подвыборках обучающих данных со случайным выбором признаков в каждом узле. Итоговое предска-

Таблица 4 — Сетка гиперпараметров гребневой регрессии с ядрами

Гиперпараметр	Перебираемые значения
Тип ядра	rbf, poly, sigmoid
Коэффициент регуляризации α	10^{-4} , 10^{-3} , 10^{-2} , 10^{-1}
Параметр ядра γ	0,1; 0,2; ...; 1,0
Предобработка признаков	стандартизация (StandardScaler)
Критерий отбора	$\min(\text{MAE}_h + \text{MAE}_p)$ на валидации

ние получается усреднением предсказаний отдельных деревьев, что снижает дисперсию модели и обеспечивает устойчивость к переобучению. В отличие от ядерных методов, случайный лес не требует масштабирования признаков и естественным образом обрабатывает нелинейные зависимости и признаки разной природы (вещественные и бинарные).

Важным преимуществом метода является возможность оценки важности признаков по суммарному вкладу каждого из них в уменьшение дисперсии при разбиениях, что обеспечивает интерпретируемость модели. Подбор гиперпараметров проведён двумерным перебором по числу деревьев и максимальной глубине (таблица 5); критерием служила усреднённая нормированная ошибка $\frac{1}{2}(\widetilde{\text{MAE}}_h + \widetilde{\text{MAE}}_p)$ на валидации. Оптимальной признана конфигурация с числом деревьев 500 и максимальной глубиной 20.

Таблица 5 — Сетка гиперпараметров случайного леса

Гиперпараметр	Перебираемые значения
Число деревьев <code>n_estimators</code>	10, 50, 100, 200, 300, 400, 500, 600
Максимальная глубина <code>max_depth</code>	5, 10, 15, 20, 25
Критерий отбора	$\min$ усреднённой нормированной MAE на валидации
Оптимальные значения	<code>n_estimators = 500</code> , <code>max_depth = 20</code>

4.3 Программная реализация классических моделей

Обе классические модели реализованы на языке Python с использованием библиотек NumPy, pandas, SciPy и scikit-learn [7]. Конвейер обработки построен единообразно: класс-контейнер `SimulationPoint` хранит параметры и вычисленные признаки одной симуляции, набор функций-анализаторов

извлекает дескрипторы из файлов результатов, после чего данные агрегируются в таблицу `pandas.DataFrame`, разбиваются на выборки и подаются в модель. Извлечение коэффициента диффузии из кривой среднеквадратичного смещения иллюстрирует Листинг 1.

Листинг 1 — Извлечение коэффициента диффузии из кривой MSD

```
1     def analyze_msd(points_dict, data_dir, threshold):
2     for pt in points_dict.values():
3         filepath = os.path.join(data_dir, f"Sigma2t_{pt.rho}_{pt.h}_{pt.temp}_{pt.mu}.
4         txt")
5         msd = np.loadtxt(filepath)
6         time = np.arange(len(msd))
7         half_idx = len(msd) // 2
8         # Наклон линейного участка MSD:  $D = slope / 4$  квазидвумерный( случай)
9         k, b = np.polyfit(time[half_idx:], msd[half_idx:], 1)
10        pt.diffusion_coeff = k / 4.0
11        pt.mobility_phase = 'Liquid' if pt.diffusion_coeff >= threshold else 'Crystal'
```

5 Графовая нейронная сеть

5.1 Графовые свёрточные сети

Графовые нейронные сети обобщают идею свёртки на данные с нерегулярной структурой связей. Базовой операцией является передача сообщений (message passing): признаковое представление каждой вершины обновляется агрегированием информации от соседних вершин и связывающих рёбер. В отличие от классических методов, графовая сеть не требует ручного конструирования признаков — информативное представление формируется автоматически в процессе обучения непосредственно из геометрии системы.

В настоящей работе используется кристаллическая графовая свёртка CGConv [8], специально приспособленная для работы с признаками рёбер. Обновление признака вершины i выполняется по правилу

$$\mathbf{x}'_i = \mathbf{x}_i + \sum_{j \in \mathcal{N}(i)} \sigma(\mathbf{z}_{ij} \mathbf{W}_f + \mathbf{b}_f) \odot g(\mathbf{z}_{ij} \mathbf{W}_s + \mathbf{b}_s), \quad \mathbf{z}_{ij} = \mathbf{x}_i \oplus \mathbf{x}_j \oplus \mathbf{e}_{ij}, \quad (11)$$

где $\mathcal{N}(i)$ — множество соседей вершины i , $\oplus$ — конкатенация, σ — сигмоидальная функция-вентиль, g — функция активации, $\odot$ — поэлементное произведение, $\mathbf{W}_f, \mathbf{W}_s, \mathbf{b}_f, \mathbf{b}_s$ — обучаемые параметры. Использование признаков рёбер $\mathbf{e}_{ij} = (\Delta x, \Delta y, \Delta z, r)$ позволяет сети напрямую учитывать взаимное расположение частиц в трёхмерном пространстве.

5.2 Архитектура модели PhysicsGNN

Разработанная модель PhysicsGNN состоит из блока эмбединга вершин, трёх последовательных графовых свёрток CGConv с пакетной нормализацией, операции глобального усреднения по графу, конкатенации с плотностью и двух полносвязных слоёв, формирующих итоговое предсказание. Поскольку все вершины имеют скалярный единичный признак, эмбединг переводит его в скрытое представление размерности 32. После трёх свёрток признаки всех вершин усредняются в единый вектор графа, к которому добавляется значение плотности ρ ; полученный вектор подаётся на полносвязный регрессионный блок. Послойная структура сети приведена в таблице 6.

Реализация прямого прохода сети приведена в Листинге 2; полный код модели вынесен в приложение Б.

Таблица 6 — Архитектура графовой нейронной сети PhysicsGNN

№	Слой (тип)	Размерность	Назначение
1	Эмбединг (Linear + ReLU)	$1 \rightarrow 32$	Перевод признака вершины в скрытое пространство
2	CGConv #1 (+ BatchNorm, ReLU)	$32 \rightarrow 32$	Передача сообщений по рёбрам ($\dim \mathbf{e} = 4$)
3	CGConv #2 (+ BatchNorm, ReLU)	$32 \rightarrow 32$	Расширение рецептивного поля
4	CGConv #3 (+ BatchNorm, ReLU)	$32 \rightarrow 32$	Агрегация структурной информации
5	Global Mean Pool	$32 \rightarrow 32$	Свёртка графа в единый вектор
6	Конкатенация с ρ	$32 \rightarrow 33$	Добавление глобального признака плотности
7	FC #1 (Linear + ReLU)	$33 \rightarrow 32$	Скрытый регрессионный слой
8	FC #2 (Linear)	$32 \rightarrow 2$	Выход: (h, p)

Листинг 2 — Прямой проход модели PhysicsGNN

```

1  def forward(self, x, edge_index, edge_attr, batch_idx, rho):
2      x = F.relu(self.node_emb(x))                # эмбединг вершин
3      x = F.relu(self.conv1(x, edge_index, edge_attr))
4      x = F.relu(self.conv2(x, edge_index, edge_attr))
5      x = F.relu(self.conv3(x, edge_index, edge_attr))
6      x_graph = global_mean_pool(x, batch_idx)    # вектор графа
7      rho = rho.view(-1, 1)
8      x_combined = torch.cat([x_graph, rho], dim=1) # добавляем плотность
9      out = F.relu(self.fc1(x_combined))
10     return self.fc2(out)                        # предсказание (h, p)
11

```

5.3 Обучение модели

Целевые величины h и p различаются по масштабу более чем на порядок, поэтому перед обучением они нормируются в диапазон $[0, 1]$ методом минимакс-нормализации:

$$\tilde{y} = \frac{y - y_{\min}}{y_{\max} - y_{\min} + \varepsilon}, \quad (12)$$

где $\varepsilon = 10^{-6}$ — малая добавка для устойчивости. Это уравнивает вклад обеих величин в функцию потерь. В качестве функции потерь используется среднеквадратичная ошибка на нормированных целях:

$$\mathcal{L} = \frac{1}{N} \sum_{i=1}^N \|\hat{\mathbf{y}}_i - \tilde{\mathbf{y}}_i\|_2^2. \quad (13)$$

Оптимизация выполняется методом Adam [13] с понижением скорости обучения по стратегии ReduceLROnPlateau (множитель 0,5, терпение 5 эпох) при отсутствии улучшения ошибки на валидации. На каждой эпохе после прохода по валидационной выборке сохраняется модель с наименьшей валидационной ошибкой. Параметры обучения сведены в таблицу 7. На этапе предсказания нормированный выход сети обратным преобразованием переводится в физические единицы, после чего предсказания по четырём патчам каждой симуляции усредняются.

Таблица 7 — Гиперпараметры и настройки обучения графовой сети

Параметр	Значение
Скрытая размерность <code>hidden_dim</code>	32
Число свёрточных слоёв <code>CGConv</code>	3
Размер батча	16
Число эпох	50
Начальная скорость обучения	0,005
Оптимизатор	Adam
Планировщик	ReduceLROnPlateau (factor 0,5; patience 5)
Функция потерь	MSE (на нормированных целях)
Нормировка целей	минимум в $[0, 1]$

5.4 Подбор гиперпараметров

Для определения оптимальной конфигурации сети выполнен перебор по сетке скрытой размерности, скорости обучения и размера батча (таблица 8), всего восемь экспериментов по 20 эпох. Качество оценивалось по коэффициенту R^2 для дипольного момента на тестовой выборке. По итогам перебора для финальной модели приняты значения `hidden_dim` = 32, скорость обучения 0,005 и размер батча 16, обеспечивающие наилучший баланс каче-

ства и устойчивости обучения.

Таблица 8 — Сетка перебора гиперпараметров графовой сети

Гиперпараметр	Перебираемые значения
Скрытая размерность <code>hidden_dim</code>	32, 64
Скорость обучения	0,005; 0,001
Размер батча	16, 32
Число эпох на эксперимент	20
Критерий отбора	$\max R_p^2$ на тесте

5.5 Программная реализация

Модель реализована на PyTorch [10] с использованием библиотеки PyTorch Geometric [9], предоставляющей слой `CGConv`, загрузчик графовых данных и операции пулинга. Конвейер разделён на независимые модули: подготовка датасета (`prepare_dataset.py`), обучение (`train.py`), подбор гиперпараметров (`tune.py`), оценка качества (`evaluate.py`) и построение дополнительных графиков (`plots.py`). Такая организация обеспечивает воспроизводимость экспериментов и удобство сопровождения кода.

6 Анализ результатов

6.1 Результаты классических моделей

Подбор гиперпараметров для гребневой регрессии (KRR) и случайного леса (RF) производился на валидационной выборке с использованием поиска по сетке (Grid Search). Для KRR исследовалась зависимость суммарной средней абсолютной ошибки (MAE) от ширины ядра γ и коэффициента регуляризации α для трёх типов ядер: полиномиального, радиально-базисного (RBF) и сигмоидального.

На рисунке 1 представлены тепловые карты ошибок для всех трёх типов ядер. Наилучший результат для KRR достигнут с использованием RBF-ядра при $\alpha = 0,0001$ и $\gamma = 0,2$.




Рисунок 1 — Тепловые карты MAE на валидационной выборке для моделей KRR

Для модели случайного леса (RF) оптимизировались количество деревьев ($n_estimators$) и их максимальная глубина (max_depth). Зависимость комбинированной нормированной ошибки от этих параметров показана на рисунке 2. Оптимум, характеризующийся выходом на плато и отсутствием переобучения, достигается при 500 деревьях и глубине 20.

На рисунке 3 (слева и по центру) представлены графики соответствия (parity plots) истинных и предсказанных значений для лучшей модели RF на тестовой выборке. Модель отлично восстанавливает дипольный момент p , однако на графике для высоты конфайнмента h наблюдается выраженная дисперсия (разброс точек вокруг идеальной диагонали). Это связано с тем, что глобальные физические признаки, усреднённые по всей ячейке, слабо улавливают тонкие изменения зазора h , который в большей степени влияет на локальные 3D-перекрывания частиц.




Рисунок 2 — Двумерная тепловая карта нормированной MAE для модели случайного леса

Анализ важности признаков (рисунок 3, справа) подтверждает физическую интуицию. Наибольший вклад (более 60 %) вносит коэффициент диффузии (`diffusion_coeff`). С физической точки зрения диффузия экспоненциально зависит от силы связывания частиц (дипольного момента p). Вторым и третьим по важности признаками стали параметр порядка ψ_6 и плотность ρ , которые характеризуют формирование плотноупакованных (гексагональных) монослоёв при сильном конфайнменте.

6.2 Результаты графовой нейронной сети

Графовая нейронная сеть PhysicsGNN обучалась в течение 50 эпох. Наилучшая конфигурация была получена при размерности скрытого слоя 32, размере батча 16 и скорости обучения 0,005. Итоговые метрики модели на отложенной тестовой выборке представлены на рисунке 4 и в таблице 9.

Модель PhysicsGNN демонстрирует выдающиеся результаты: коэффициент детерминации R^2 превышает 0,99 для обеих целевых величин. Особенно важно отметить кардинальное улучшение предсказания высоты конфайн-




Рисунок 3 — Результаты Random Forest: предсказания h и p , а также важность признаков




Рисунок 4 — Графики истинных и предсказанных значений (h и p) для PhysicsGNN

мента h по сравнению с классическими моделями.

Для углублённого анализа ограничений модели было построено пространственное распределение абсолютной ошибки предсказания дипольного момента Δp в фазовых координатах h – p (рисунок 5, слева).

Наибольшие ошибки (тёмные точки на фазовой карте) концентрируются в областях низких значений дипольного момента ($p \lesssim 2$). Физически это объясняется тем, что при малых p система представляет собой изотропную жидкость, где тепловые флуктуации доминируют над диполь-дипольным взаимодействием. В таких условиях структура хаотична, и извлечь точное значение параметра взаимодействия из геометрии становится принципиально сложно.

Зависимость ошибки от плотности ρ (рисунок 5, справа) также показы-




Рисунок 5 — Пространственное распределение ошибки (слева) и зависимость ошибки от плотности (справа) для PhysicsGNN

вает, что при минимальной плотности ($\rho = 0,3$) дисперсия ошибки максимальна: разреженный газ коллоидных частиц формирует мало информативных графовых связей (рёбер), что снижает качество агрегации сообщений в нейронной сети. При плотностях $\geq 0,5$ сеть работает стабильно высоко.

6.3 Сравнительный анализ моделей

Для итогового сравнения в таблице 9 сведены метрики трёх разработанных алгоритмов на тестовой выборке (для GNN метрики рассчитаны после усреднения предсказаний по 4 патчам).

Таблица 9 — Сравнение метрик качества моделей на тестовой выборке

Модель	R^2 для h	MAE для h	R^2 для p	MAE для p
KRR (RBF)	0,904	0,027	0,971	0,312
Random Forest	0,909	0,031	0,984	0,320
PhysicsGNN	0,996	0,006	0,997	0,183

Как видно из таблицы, PhysicsGNN является безусловным лидером. В то время как классические модели неплохо справляются с предсказанием дипольного момента за счёт явного включения коэффициента диффузии в признаки, они терпят неудачу при предсказании высоты h .

Преимущество графовой нейронной сети обусловлено тем, что она получает на вход «сырые» относительные 3D-координаты частиц ($\Delta x, \Delta y, \Delta z, r$) в качестве признаков рёбер. В условиях конфайнмента параметр h напрямую лимитирует распределение частиц вдоль оси Z . Свёртка CGConv способна

извлечь эту геометрическую зависимость напрямую из тензора связей, избегая потери информации, которая неизбежно происходит при ручном конструировании усреднённых дескрипторов (таких как ψ_6 или число слоёв).

ЗАКЛЮЧЕНИЕ

В ходе выполнения курсового проекта была успешно решена обратная задача восстановления управляющих параметров молекулярно-динамической симуляции (высоты геометрического ограничения h и дипольного момента частиц p) по наблюдаемой равновесной пространственной структуре коллоидной системы.

Основные результаты работы:

1. Разработан полный программный конвейер для обработки «сырых» траекторий молекулярной динамики из пакета HOOMD-blue. Сформирован набор данных, включающий 8757 уникальных равновесных конфигураций частиц при различных плотностях.
2. Проведён физический анализ структур, реализовано автоматическое извлечение 13 структурно-динамических дескрипторов (коэффициент диффузии, параметры порядка ψ_n , характеристики триплетов и змеек).
3. Разработаны и протестированы базовые (baseline) модели машинного обучения на основе агрегированных признаков — гребневая регрессия с ядрами (KRR) и случайный лес (Random Forest). Анализ важности признаков показал ожидаемую зависимость предсказаний от подвижности частиц и локальной гексагональной симметрии.
4. Реализовано геометрическое представление данных в виде графов с применением метода вырезания пространственных патчей, что позволило в 4 раза увеличить объём обучающей выборки и решить проблему вычислительной сложности больших графов.
5. Разработана и успешно обучена графовая свёрточная нейронная сеть PhysicsGNN на базе архитектуры CGConv. Доказано, что обработка непосредственной геометрии системы (векторов связей) многократно превосходит классические подходы: R^2 для дипольного момента составил 0,997, а для высоты конфайнмента — 0,996.

Практическая значимость работы заключается в возможности применения обученной суррогатной модели PhysicsGNN для быстрого анализа экспериментальных конфокальных снимков коллоидных ансамблей. Модель позволяет с высокой точностью определять эффективную толщину зазора микрофлюидной ячейки и локальную напряжённость магнитного поля без проведения дорогостоящих вычислений, что открывает новые перспективы в за-

дачах автоматизированного дизайна мягких материалов и «лабораторий-на-чипе».

Список литературы

- [1] Boles M. A., Engel M., Talapin D. V. Self-Assembly of Colloidal Nanocrystals: From Intricate Structures to Functional Materials // Chemical Reviews. — 2016. — Vol. 116, № 18. — P. 11220–11289.
- [2] Li Z., Fan Q., Yin Y. Colloidal Self-Assembly Approaches to Smart Nanostructured Materials // Chemical Reviews. — 2022. — Vol. 122, № 5. — P. 4976–5073.
- [3] Solano-Cabrera C. O., Castro-Villarreal P., Moctezuma R. E., Donado F., Conrad J. C., Castañeda-Priego R. Self-Assembly and Transport Phenomena of Colloids: Confinement and Geometrical Effects // Annual Review of Condensed Matter Physics. — 2025. — Vol. 16. — P. 41–63.
- [4] Zhukov K. P., Kokhanovskaia A. V., Nafikova R. R. [et al.] Self-assembly of various structures in colloidal systems with controlled interactions under confinement conditions // Centre for Soft Matter and Physics of Fluids, Bauman Moscow State Technical University. — 2026. — P. 1–6.
- [5] Yakovlev E. V., Komarov K. A., Zaytsev K. I. [et al.] Tunable two-dimensional assembly of colloidal particles in rotating electric fields // Scientific Reports. — 2017. — Vol. 7. — P. 13727.
- [6] Breiman L. Random Forests // Machine Learning. — 2001. — Vol. 45, № 1. — P. 5–32.
- [7] Pedregosa F., Varoquaux G., Gramfort A. [et al.] Scikit-learn: Machine Learning in Python // Journal of Machine Learning Research. — 2011. — Vol. 12. — P. 2825–2830.
- [8] Xie T., Grossman J. C. Crystal Graph Convolutional Neural Networks for an Accurate and Interpretable Prediction of Material Properties // Physical Review Letters. — 2018. — Vol. 120, № 14. — P. 145301.
- [9] Fey M., Lenssen J. E. Fast Graph Representation Learning with PyTorch Geometric // ICLR Workshop on Representation Learning on Graphs and Manifolds. — 2019.

- [10] Paszke A., Gross S., Massa F. [et al.] PyTorch: An Imperative Style, High-Performance Deep Learning Library // Advances in Neural Information Processing Systems. — 2019. — Vol. 32. — P. 8024–8035.
- [11] Anderson J.A., Lorenz C.D., Travesset A. General purpose molecular dynamics simulations fully implemented on graphics processing units // Journal of Computational Physics. — 2008. — Vol. 227, № 10. — P. 5342–5359.
- [12] Glaser J., Nguyen T.D., Anderson J.A. [et al.] Strong scaling of general-purpose molecular dynamics simulations on GPUs // Computer Physics Communications. — 2015. — Vol. 192. — P. 97–107.
- [13] Kingma D.P., Ba J. Adam: A Method for Stochastic Optimization // 3rd International Conference on Learning Representations (ICLR). — 2015.